

Entre Palavras e Watts

DESINFORMAÇÃO E CUSTO ENERGÉTICO EM LLMS

UFRN | PPGEEC

Redes Neurais — Deep Learning
Prof. Adrião Duarte Doria Neto

AUTORES

Minnael Campelo de Oliveira
Gustavo Pereira de Carvalho

PERÍODO

2026.1

Roteiro

Trabalho 1: Desinformação

1. Motivação e o problema em Bangla
2. Dados e geração com 7 LLMs
3. Pipeline de detecção (ML/DL)
4. Resultados e análise linguística

Trabalho 2: Custo Energético

5. Motivação e contexto do consumo
6. Setup experimental: Hardware
7. Eficiência e Power Capping

Síntese e Conclusão

8. Discussão comparativa
9. Conclusões e Referências

Trabalho 1: Desinformação em Bangla

"Generation, Analysis, and Detection of LLM Manipulated Bangla News" — IEEE Access, 2025

⚠ O Problema

- LLMs geram textos sintéticos altamente convincentes.
- Notícias falsas tornam-se quase indistinguíveis de reais.
- Bangla: 6º idioma mais falado, mas com poucos datasets sintéticos.

🎯 Objetivos

- Gerar notícias manipuladas em Bangla usando 7 LLMs.
- Analisar linguisticamente as produções dos modelos.
- Detectar automaticamente a autenticidade dos textos.

Conexão Acadêmica

Aplicação de arquiteturas estudadas na disciplina — **CNN, LSTM** — para resolver um problema real de classificação de texto e segurança informacional.

Dataset e Geração

Corpus KUMono

Base Real: 1,3 milhão de artigos em Bangla.

Amostra: 5.000 artigos autênticos selecionados (Política, Saúde, Esportes, etc.).

>_ Estratégia de Prompt

Instrução fixa para alterar nomes, locais e datas, mantendo o tema e o sentimento original. **Temperature = 0.9** para garantir diversidade e plausibilidade.

7 LLMs Utilizados (35k Artigos)

Modelo	Família	Parâmetros
Gemma-27b / 9b	Google	27B / 9B
Llama-8b / 3b	Meta	8B / 3B
Phi-15b	Microsoft	15B
Mistral-12b	NVIDIA	12B
GPT-21b (OSS)	OpenAI-style	21B (3B ativos)

Total de 5.000 notícias falsas geradas por cada modelo, resultando em um dataset sintético robusto.

Pipeline de Detecção Multimodal

Processamento de Linguagem Natural em Bangla

MACHINE LEARNING

- **Extração:** TF-IDF, Bag of Words (BOW), CountVectorizer.
- **Modelos:** SVM, Regressão Logística, Random Forest, Naive Bayes.
- Foco em padrões estatísticos de frequência de palavras.

DEEP LEARNING

- **Embeddings:** FastText e Integer Sequencing para contexto semântico.
- **Arquiteturas:** CNN (espacial), Bi-LSTM (sequencial) e GRU.
- Captura de dependências de longo prazo no texto.

KNOWLEDGE-BASED

- **NER:** Extração de Entidades Nomeadas (Pessoas, Locais, Datas).
- **Verificação:** Busca web automatizada para checagem de fatos.
- Cálculo de Score de Autenticidade baseado em fontes reais.

Métricas de Avaliação:

ACURÁCIA

PRECISÃO

RECALL

F1-SCORE

FNR (Falsos Negativos)

Resultados: Eficácia da Detecção

DESEMPENHO POR ABORDAGEM

Abordagem	Acurácia	F1-Score
Deep Learning (Bi-LSTM/GRU)	~95%	~0.95
Machine Learning (LR + TF-IDF)	~92%	~0.92
Knowledge-Based ★	~91%	~0.91


★ A abordagem baseada em conhecimento obteve o **menor FNR** (Falsos Negativos), sendo crucial para segurança.

ANÁLISE LINGUÍSTICA


- Gemma-27b:** Gerou textos mais similares ao padrão humano (comprimento e PoS).
- Mistral-12b:** Maior taxa de erros gramaticais (WER $\approx$ 2,53%).

INSIGHT CHAVE

Textos gramaticalmente perfeitos enganam redes neurais; a detecção de manipulações factuais é o diferencial da abordagem baseada em conhecimento.



Accuracy of machine learning models for LLM-manipulated Bangla news detection.



Accuracy of deep learning models for LLM-manipulated Bangla news detection.

Trabalho 2: Custo Energético da Inferência em LLMs

"From Words to Watts: Benchmarking the Energy Costs of LLM Inference" – MIT/IEEE HPEC, 2023

⚡ O Problema

- O treinamento de LLMs é caro.
- O custo energético do uso diário é sub-estudado na literatura.
- ChatGPT recebe ~10 milhões de queries/dia: cada uma custa energia real.

🔧 Desafios de Produção

- Quantas GPUs são necessárias para manter o serviço?
- Qual o consumo por token gerado?
- Existem trade-offs eficientes entre tempo e energia?

🌱 Sustentabilidade

Complementa o estudo de Deep Learning com a perspectiva de **custo computacional e impacto ambiental**, essencial para a implantação ética de modelos em larga escala.

Setup Experimental

HARDWARE (MIT SUPERCLOUD)

NVIDIA V100 (32GB): Experimentos distribuídos em larga escala.

NVIDIA A100 (80GB): Alta performance em configurações de menos shards.

DATASETS DE TESTE

Alpaca: 4.096 amostras de instruções em linguagem natural.

GSM8K: 4.096 problemas de raciocínio matemático.

CPU			GPU		
Type	Memory (GB)	TDP (W)	Type	Memory (GB)	TDP (W)
Intel Xeon Gold 6248	384	150	V100	32	250
Intel Xeon Platinum 8358	503	240	A100	80	300

Setup Experimental

HARDWARE (MIT SUPERCLOUD)

NVIDIA V100 (32GB): Experimentos distribuídos em larga escala.

NVIDIA A100 (80GB): Alta performance em configurações de menos shards.

DATASETS DE TESTE

Alpaca: 4.096 amostras de instruções em linguagem natural.

GSM8K: 4.096 problemas de raciocínio matemático.


MODELOS LLAMA AVALIADOS

Variante	Parâmetros	GPUs Mínimas (V100)
LLaMA 7B	7 Bilhões	1 GPU
LLaMA 13B	13 Bilhões	2 GPUs
LLaMA 65B	65 Bilhões	8 GPUs


MÉTRICAS COLETADAS

Tokens por segundo (Throughput), Energia por segundo (Watts), Energia por token (Joules) e Energia por resposta completa.

Resultados: Performance de inferência



(a) Results from the Alpaca dataset.



(b) Results from GSM8K dataset

Resultados: Eficiência Energética



ESTRATÉGIA DE POWER CAPPING (A100)

Limite (Cap)	Δ Tempo	Δ Energia
250W → 175W	+6,23%	-21,82% ★
250W → 150W	+15,33%	-32,76%

★ Recomendação.

CUSTO POR TOKEN (LLAMA 65B)

3 a 4 Joules por token gerado



Referências Bibliográficas

- [1] **AKTHER, A. et al.** Generation, Analysis, and Detection of LLM Manipulated Bangla News. **IEEE Access** , vol. 13, pp. 216870–216889, 2025.
- [2] **SAMSI, S. et al.** From Words to Watts: Benchmarking the Energy Costs of LLM Inference. **IEEE HPEC** , 2023.
- [3] **VASWANI, A. et al.** Attention Is All You Need. **NeurIPS** , 2017.
- [4] **TOUVRON, H. et al.** LLaMA: Open and Efficient Foundation Language Models. **Meta AI** , 2023.
- [5] **AKTHER, A. et al.** Compilation, Analysis and Application of a Comprehensive Bangla Corpus KUMono. **IEEE Access** , vol. 10, 2022.
- [6] **STRUBELL, E. et al.** Energy and Policy Considerations for Deep Learning in NLP. **ACL** , 2019.